



DLCAS :A Deep Learning-Based CPR Action Standardization Method

汇报人 殷明捷
2024年5月30日



报告大纲

Contents

1. Introduction

2. Methods

3. Experiment

4. Conclusions

1.Introduction

院外心脏骤停（OHCA）是一个重大的公共卫生挑战，全球成年人平均每10万人年发生55起院外心脏骤停事件。在中国，有超过2.3亿心血管疾病患者，每年有55万人经历心脏骤停。全球范围内，心脏骤停后的生存率仍然很低，在中国，院外心脏骤停的生存率不到1%。研究表明，早期启动CPR、良好的CPR质量和使用自动体外除颤器（AED）可以显著改善院外心脏骤停患者的生存率和长期预后。

Table 1 The incidence of ROSC, survival to admission, survival to discharge, 1 month survival, and 1 year survival: the overall estimates and subgroup analyses

	No. of reports	Survivors	OHCA cases	Proportion (%)	95%CI	I^2	P value for heterogeneity
ROSC*	74	203,084	1,560,830	29.7	27.6 to 31.7	99.90%	< 0.001
Sex							
Men	2	242	856	28.9	24.2 to 33.6	43.4%	0.184
Women	2	151	478	31.6	27.4 to 35.8	0.00%	0.542
Combined	70	202,691	1,559,496	29.7	27.6 to 31.8	99.90%	< 0.001
Study location							
Europe	32	4166	12,274	36.7	32.4 to 40.9	96.10%	< 0.001
Asia	17	186,060	1,500,110	22.1	18.1 to 26.0	100.00%	< 0.001
North America	20	6981	32,520	24.3	19.7 to 28.9	99.10%	< 0.001
Oceania	5	5877	15,926	38.6	22.9 to 54.2	99.20%	< 0.001

1.Introduction

本论文提出了一种基于AED的CPR动作标准检测方法，利用骨骼关键点辅助姿势估计。该方法通过识别救援者手腕上的标记手环来测量压迫深度、频率和次数。考虑到边缘设备上目标检测网络的局限性，我们基于Yolo-FastestV2开发了CPR-Detection算法。该算法不仅提高了检测准确性，还简化了模型结构。在此算法的基础上，我们设计了一种新颖的压迫深度计算方法，通过分析手环的位移来映射实际深度。我们还优化了网络，以提高边缘设备上的速度和准确性，确保对被救助者的压迫深度进行精确测量，保护其安全。此外，我们还针对边缘设备优化了计算方法。

该论文的主要贡献包括：

1. 我们引入了一种称为基于深度学习的CPR动作标准化（DLCAS）的新方法，并开发了自定义的CPR动作数据集。此外，我们还结合OpenPose进行救援者姿势估计。
2. 我们提出了一种名为CPR-Detection的目标检测模型，并介绍了各种优化其结构的方法。在此基础上，我们通过分析手环位移数据开发了一种测量压迫深度的新方法。
3. 我们提出了一种针对自动体外除颤器（AED）边缘设备的优化部署方法。该方法解决了当前边缘设备部署深度学习算法存在的模型推理时间长、准确性低的问题。
4. 我们进行了广泛的实验证实，以确认改进的算法的有效性和压迫深度测量方案的可行性。



报告大纲

Contents

1. Introduction
2. **Methods**
3. Experiment
4. Conclusions

2.Methods



如图1所示，本研究的总体工作流程分为三个部分。第一部分是实验准备阶段，包括数据集收集、图像预处理和增强、数据集划分、训练，并测试训练好的模型以获得性能指标。第二部分介绍了DLCAS的流程图，包括姿势估计、目标检测网络和深度测量，最终得出压迫深度、压迫次数和频率。第三部分描述了模型的推理和应用。通过优化的AED边缘设备处理，捕获的图像最终成为具有易于评估指标的CPR图像。

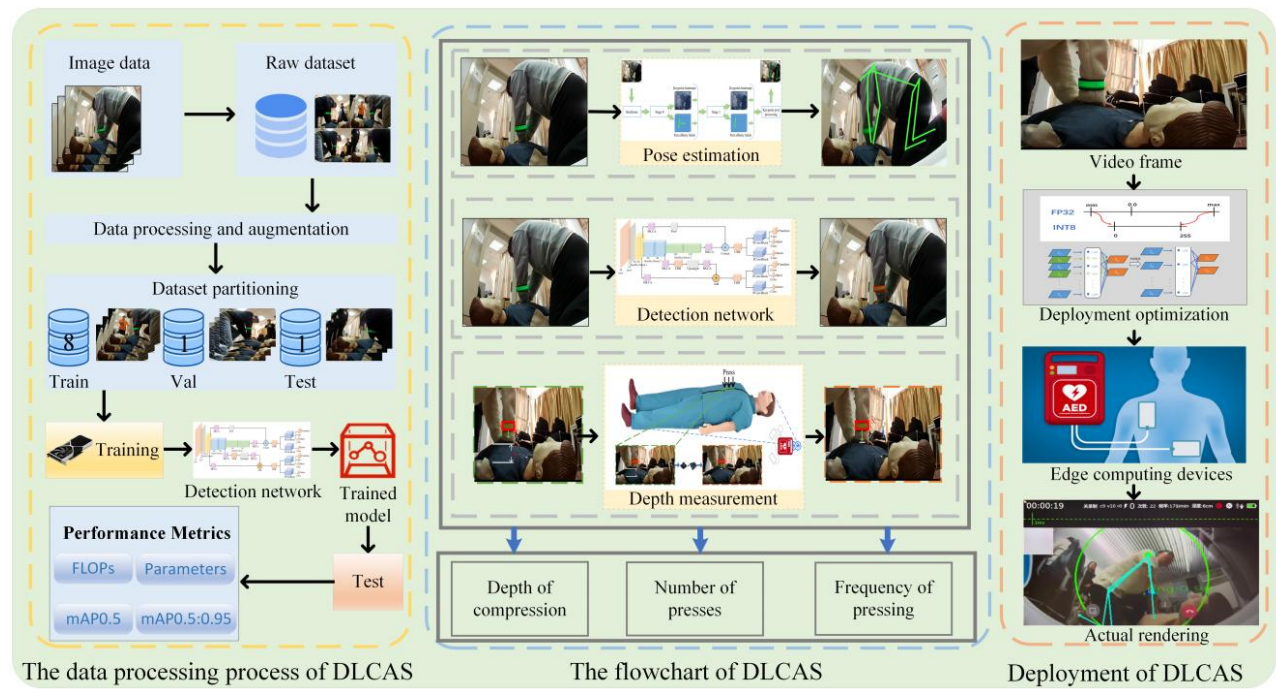


Figure 1. The overall working flow chart.

2.Methods

2.1. OpenPose

如图2所示，OpenPose的工作流程始于通过主干网络进行特征提取。这些特征经过Stage 0处理，生成关键点热图和PAFs（Part Affinity Fields）。根据PAFs将关键点组合起来形成连贯而准确的人体姿势表示。

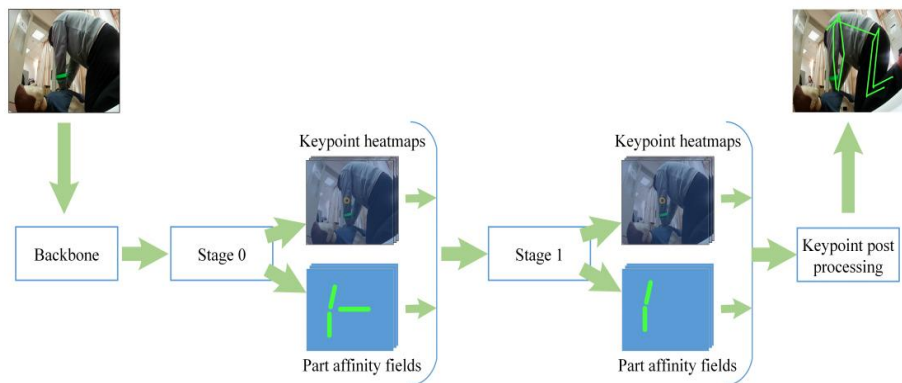


Figure 2. Overall framework of OpenPose.

2.2. CPR-Detection

在本研究中，我们详细解释了CPR-Detection。如图3所示，该模型由三个组件组成：主干网络ShuffleNetV2、STD-FPN特征融合模块和检测头部。STD-FPN特征融合模块采用了MLCA注意力机制，而检测头部集成了PConv位置增强卷积。

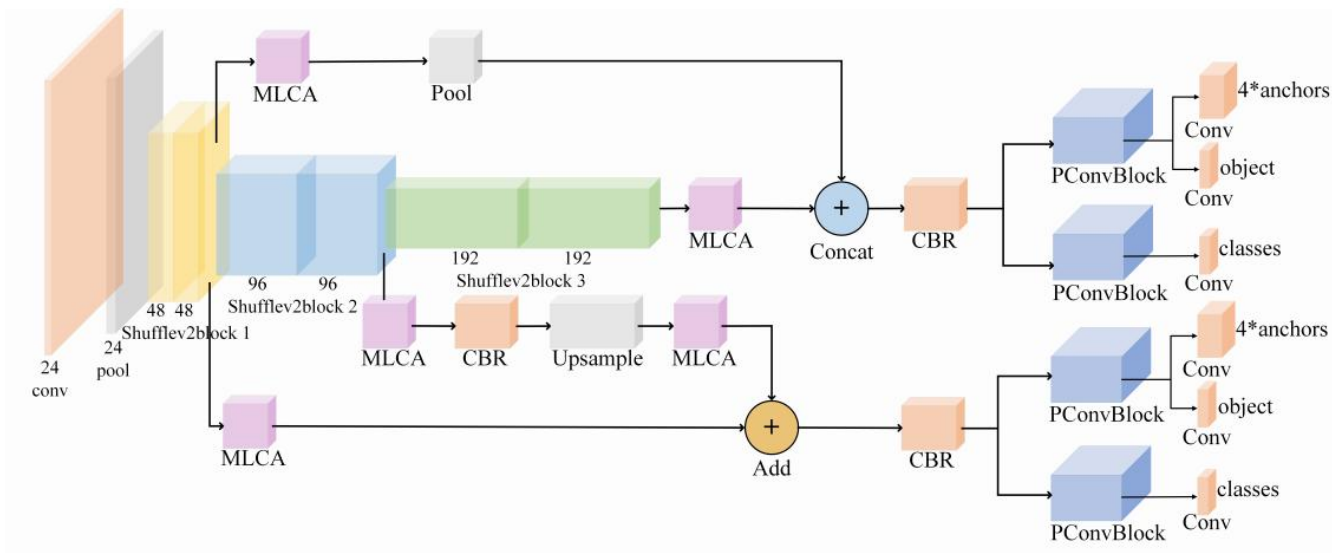


Figure 3. Overall framework of CPR-Detection.

2.Methods

2.3. Depth Measurement Method

在传统的单目相机距离测量中，直接测量深度是具有挑战性的，因为缺乏立体视觉信息。为了解决这个问题，本研究采用了一种创新方法，如图7所示，使用固定长度的标记手环作为深度校准工具。通过将标记的已知长度与相机捕获的图像进行比较，我们实现了对实际压迫深度的精确映射计算。




Figure 7. Depth ranging schematic.

2.4. Edge Device Algorithm Optimization

鉴于现有边缘设备的计算能力有限，需要一种特殊的优化方法来提高CPR动作识别的及时性，这需要高准确性和实时处理。如图8所示，深度学习算法模型首先被转换为与相应NPU兼容的权重。在这个转换过程中，采用MMSE算法和无损修剪来获得更轻量级的权重。接下来，设计了一个多线程方案。CPU上的两个线程负责算法的预处理和后处理，而NPU上的一个线程负责推理阶段。在预处理和后处理阶段都应用了RGA方法进行图像处理。最后，在算法的编译阶段使用NEON指令。

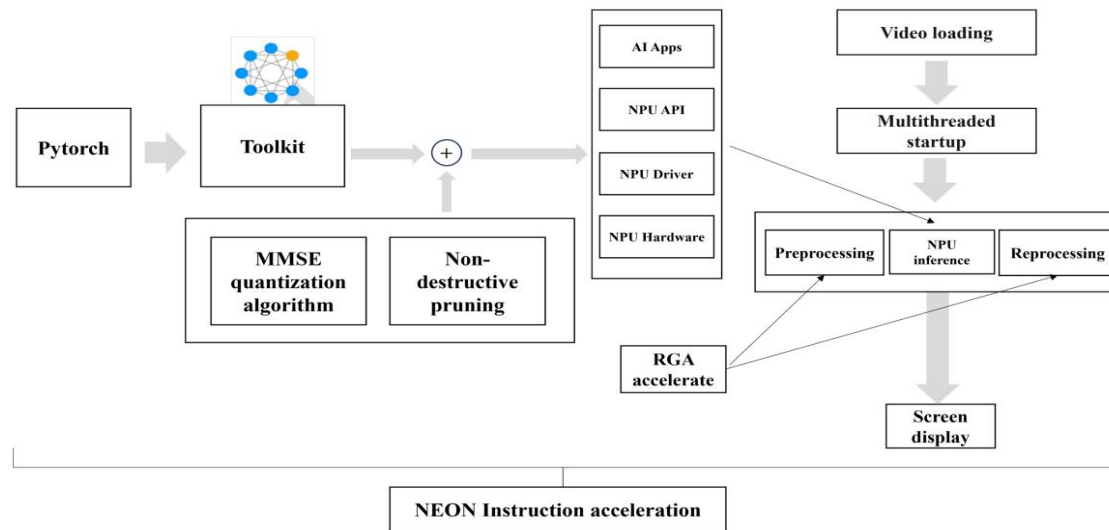


Figure 8. Edge device computing optimization flow chart.



报告大纲

Contents

1. Introduction
2. Methods
3. Experiment
4. Conclusions

3. Experiment

3.1. Datasets and Data Pre-Processing

本研究使用的数据集包含南京邮电大学学生志愿者在不同场景下捕捉的CPR动作视频帧。这些视频涵盖了不同的室内和室外环境以及光照条件。原始数据集包含1,479张图像，经过增强后达到8,874张图像。为了确保模型的稳健性和泛化能力，将数据集按照8:1:1的比例划分为训练集、测试集和验证集，分别包含7,081张、897张和896张图像。实验中使用的标记手环长33.40厘米，宽3.80厘米，呈荧光绿色。为了确保高效的训练，实验使用了一块具有24 GB内存的NVIDIA GEFORCE RTX 6000 GPU。模型是在没有使用预训练权重的情况下进行训练的。为了减少过拟合并提高识别准确性，采用了图像处理和数据增强技术。



Figure 9. (a) Train batch 0 with datasets. (b) Test batch 0 labels with Datasets.

3.2. OpenPose for CPR Recognition

在使用AED设备进行CPR过程中，一些错误可能通过医生的直接观察很难检测到。因此，有必要使用OpenPose来绘制骨骼点。如图所示，识别出了三种常见的错误CPR场景：由于穿着暗色衣物而导致的手臂运动被遮挡、单膝跪地和非垂直压迫。第一种情况下，暗色衣物降低了与背景的对比度；第二种情况下，单膝跪地导致施救者的身体不稳定；第三种情况下，非垂直压迫导致力量分散。在姿势识别之后，医生可以远程提供语音提醒，使得这些本来难以检测到的错误姿势得以立即纠正。

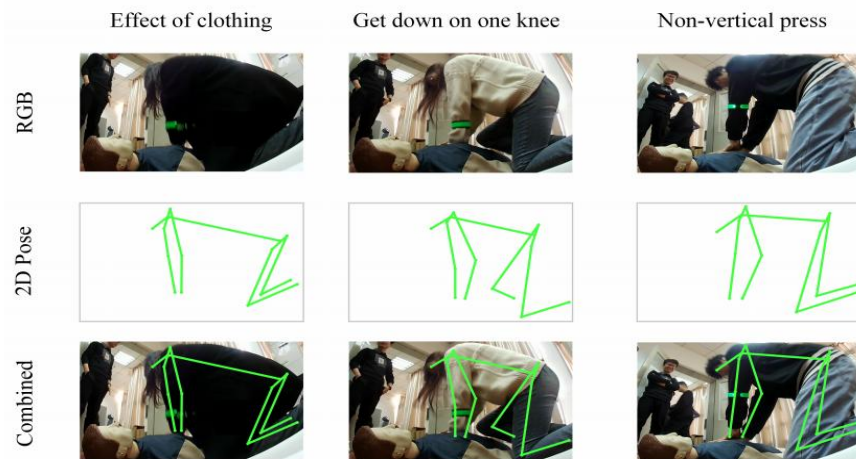


Figure 10. Common incorrect posture images (including RGB, 2D Pose, Combined).

3. Experiment

3.3. Ablation Experiment and Comparative experiment

这些改进显著提高了模型在CPR场景中识别小目标的能力，确保了更高的准确性同时保持实时检测，展示了CPR-Detection模型的优越性。三个模块的联合使用充分发挥了它们各自的优势，使得模型能够灵活适应不同的输入尺寸和应用场景，为需要高准确性和速度的医疗急救场景提供了理想的目标检测解决方案。

Table 1. Validation of the Proposed Method on Yolo-FastestV2

Index	BASE	PConv	MLCA	STD-FPN	FLOPs	Parameters	mAP0.5	mAP0.5:0.95
1	✓	✗	✗	✗	114.12K	238.50K	96.04	72.55
2	✓	✓	✗	✗	105.98K	213.30K	96.48	73.89
3	✓	✗	✓	✗	114.36K	238.52K	96.48	75.09
4	✓	✗	✗	✓	159.53K	229.38K	96.15	71.12
5	✓	✓	✓	✗	131.83K	204.18K	96.99	75.16
6	✓	✓	✗	✓	106.22K	213.32K	96.87	76.57
7	✓	✓	✓	✓	132.15K	204.20K	97.04	75.13

Table 2. Model Comparison

Method	Size	FLOPs	Parameters	mAP0.5	mAP0.5:0.95
YoloV3-Tiny	352×352	1.97G	8.66M	98.49	80.42
YoloV7-Tiny	352×352	13.2G	6.01M	96.02	66.05
NanoDet-m	352×352	0.87G	0.96M	90.20	65.70
Yolo-FastestV2	352×352	0.11G	0.23M	96.04	72.55
FastestDet	352×352	0.13G	0.23M	85.58	52.90
YoloV5-Lite	352×352	3.70G	1.54M	98.20	77.20
CPR-Detection	352×352	0.13G	0.20M	97.04	75.13

3.4. Measurement Results

图 11a 显示了 100 次压缩的深度方差分布。大多数数据点的深度误差在±1厘米以内，符合CPR操作标准并证明了测量系统的高精度。然而，少数数据点的深度误差超过1厘米，这可能是由于实验条件的变化造成的，例如相机角度或照明强度的轻微调整，这可能会影响腕带的视觉识别准确性。图 11b 显示了所进行的 100 次测量测试中每一次的准确度。设置了 90% 的准确度阈值来评估系统的性能。结果表明，绝大多数测量结果都超过了这个阈值，证实了系统在大多数情况下的高可靠性。

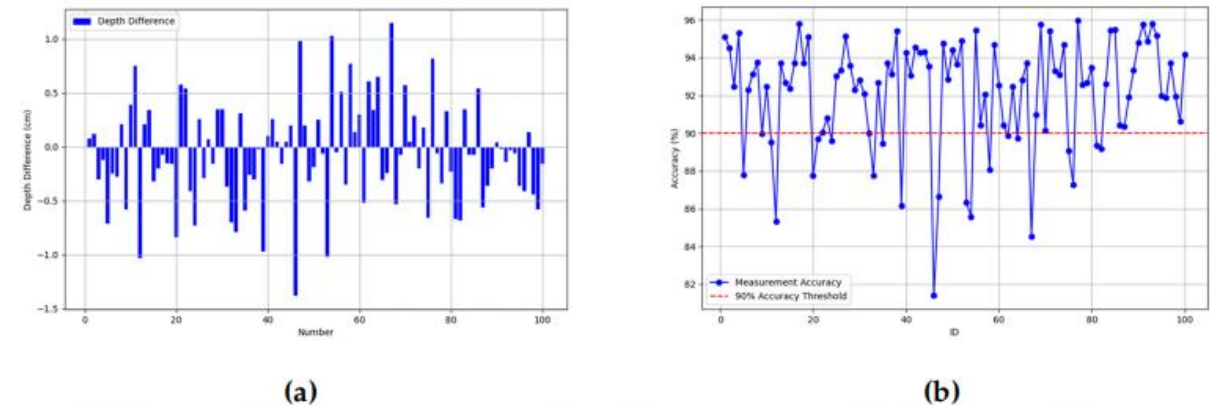


Figure 11. (a) Depth difference between actual depth and measured. (b) Measurement accuracy over time.

3. Experiment

3.5. AED Application for CPR

使用 AED 边缘设备时，用户应将腕带戴在手臂上并准备进行心肺复苏。使用过程如下：激活AED边缘设备后，数据采集单元自动启动。一旦启动智能应急功能，设备会自动启动AI识别模块，捕捉应急场景的实时图像并收集数据进行AI图像识别。

如图12所示，我们的算法在实际应用中的有效性得到了证明。我们在激活后从 AED 边缘设备视频中捕获了两帧，显示了显示的激活时间、按压次数、频率和深度。此外，我们使用 OpenPose 来可视化骨骼点，捕获按压期间手臂的局部运动轨迹。这有助于医生通过急救平台服务器评估姿势的正确性。

如图13所示，在边缘设备上优化算法后，8 FPS的初始帧率得到显着提升。通过应用量化方法，帧速率提高了 5 FPS。剪枝技术又增加了 2 FPS，异步方法又增加了 7 FPS。RGA 和 NEON 实现了进一步的增强，分别将帧速率提高了 1 FPS 和 2 FPS。总体而言，帧率从8 FPS提高到25 FPS，验证了这些优化方法的可行性。



Figure 12. Application scenario flow chart.




Figure 13. FPS Improvement through Various Optimization Steps.



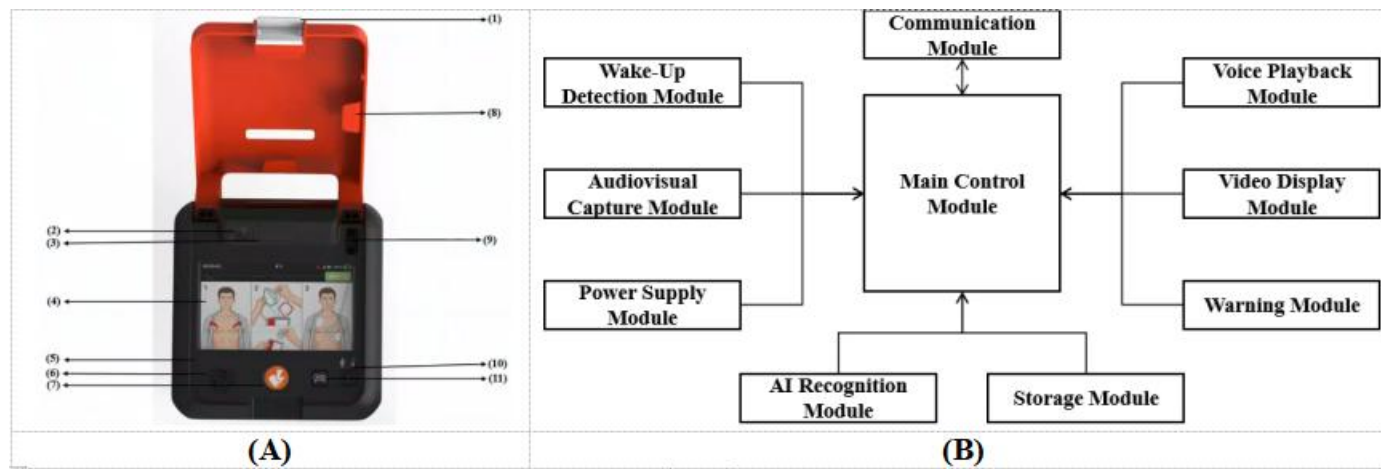
报告大纲

Contents

1. Introduction
2. Methods
3. Experiment
4. Conclusions

4. Conclusions

在本文中，我们旨在解决自动体外除颤器（AED）中缺乏标准化心肺复苏（CPR）操作的问题。我们提出了基于深度学习的CPR动作标准化（DLCAS）方法。DLCAS的第一部分利用OpenPose识别骨骼点，使远程医生能够通过联网的AED设备纠正施救者的姿势。在DLCAS的第二部分，我们设计了CPR-Detection网络。该网络使用部分卷积（PConv）通过关注关键的空间信息来增强特征表示。此外，我们在自定义的小目标检测-特征金字塔网络（STD-FPN）上采用了混合局部通道注意力（MLCA）。MLCA结合了局部和全局的上下文信息，提高了检测的准确性和效率。STD-FPN有效地融合了浅层和深层图像特征，增强了模型的定位能力。基于CPR-Detection，我们引入了一种新的深度算法来测量施救者的压迫深度、频率和次数。在DLCAS的第三部分，我们应用了计算优化方法，包括多线程CPU和NPU异步设计，RGA和NEON加速，显著提高了实时处理效率。我们在自定义数据集上进行了大量实验，结果表明我们的方法有效地解决了AED设备无法标准化CPR操作的问题。此外，我们的方法提高了边缘设备的稳定性和速度，通过性能测试验证了DLCAS方法在当前医疗场景中的适用性。





厚德 弘毅 求是 笃行



Thank You !